

資料分析專案

變換車道的外部成本

當一台車變換車道，它讓後方的車流付出多少代價
以及這個代價取決於什麼

專案概述

一份端對端的資料分析專案，從公開軌跡資料出發，建立可重現的量測流程，並將結論轉化為可落地的服務構想。

原始軌跡資料

870 萬筆

美國聯邦公路總署 NGSIM

乾淨的換道事件

2,472 次

經過四道過濾條件

配對對照組

7,591 組

最近鄰配對，不重複取樣

結論：外部成本取決於當下路況，不取決於車種。這個結果推翻了專案原本的假設。

簡報架構

01	研究問題	從車隊管理的角度定義一個沒有人在量的成本
02	資料來源	NGSIM 軌跡資料的規模、欄位與三個品質缺陷
03	技術架構	取得、清理、事件偵測、反事實設計與統計方法
04	分析結果	三個層次的發現與一個推翻假設的結論
05	商業價值	服務構想、市場對標與 AI 的角色
06	工程品質	測試、可重現性與四個資料缺陷的發現過程

01

研究問題

定義一個既有系統沒有在衡量的成本

問題的起點

車隊管理系統評分駕駛行為，衡量的全部是**對自己車輛的風險**。

急煞、超速、怠速、疲勞駕駛，每一項都在問「這個駕駛會不會出事」。

沒有任何一項在問「這個駕駛讓別人付出了多少」。

因為那個代價發生在駕駛的**後方**，他自己看不到，系統也沒有在記錄。

既有評分衡量的

急煞 · 超速 · 怠速 · 疲勞

沒有人在衡量的

我的駕駛動作，讓後方車流付出多少

三個研究問題

由淺入深，每一層都需要前一層成立才有意義。

Q-A

換道到底有沒有代價

與沒有發生換道、但條件相同的時刻相比，後車是否真的付出額外的速度損失

Q-B

誰造成的代價比較大

當換道的是貨車，後車付出的代價是否高於換道的是小客車的情況

Q-C

壅塞是否放大這個差異

同一個動作在車流順暢與嚴重壅塞下，造成的代價是否不同

專案的預設假設是貨車造成的代價更大。第四節會說明資料如何推翻這個假設。

這是一個物流問題

這份分析的對象是**貨運車輛**，不是抽象的車流。

NGSIM 的車種欄位可以把貨車單獨拆出來分析，因此物流的相關性是**結構性的**，不是事後附加的說詞。

而且結論直接改變政策該長什麼樣：

若代價來自車種，對策是車輛管制；若代價來自時機，對策是**車隊排程與駕駛行為規範**。後者是物流營運決策。

分析對象

v_class = 3，即貨車，共 352 台、7.0 車小時

對應產業

車隊 telematics 與駕駛行為評分服務

02

資料來源

公開軌跡資料的規模、欄位與已知缺陷

資料來源 NGSIM 車輛軌跡

Next Generation Simulation，美國聯邦公路總署於 2005 年執行的軌跡蒐集計畫。

以架高攝影機拍攝真實高速公路車流，逐格判讀每一台車的位置，產出**每秒 10 筆**的車輛軌跡。

透過美國運輸部開放資料平台取得，**不需要帳號或金鑰**，任何人都能重跑本專案。

授權：美國政府公共領域。

資料平台

data.transportation.gov/d/8ect-6jqj

取用方式

Socrata API，公開端點，無需驗證

資料規模與核心欄位

原始資料共 25 個欄位，本專案只取分析必需的 12 個，降低傳輸與記憶體成本。

欄位	意義	單位	用途
vehicle_id	車輛編號	—	建立軌跡
frame_id	影格編號	1 格 = 0.1 秒	時間軸與錄影批次判定
lane_id	車道編號	—	偵測換道
v_vel	速度	英尺 / 秒	量測代價的主要指標
space_headway	與前車距離	英尺	配對變數與驗證
following	正後方車輛編號	—	直接取得受影響的後車
v_class	車種	1 機車 2 小客車 3 貨車	物流切入點

路段選擇

NGSIM 共有四個路段，本專案只使用**兩個高速公路路段**。

排除的 Lankershim 與 Peachtree 是設有號誌的市區幹道。在那裡後車減速通常是因為紅燈，不是因為前方有車切入。

若納入，會把號誌造成的停等灌進「換道造成的代價」，系統性高估結論。

I-80

加州 Emeryville，約 500 公尺，4,566,387 筆

US-101

洛杉磯，約 640 公尺，4,802,933 筆

資料品質的三個缺陷

公開資料集不等於乾淨資料集。這三個缺陷都不會在摘要統計上顯現。

速度雜訊

文獻已知

速度由影像位置微分而來，含高頻雜訊。
。本專案以 1.1 秒移動平均平滑，並完全不使用加速度欄位

完全重複列

704,000 筆

US-101 有 14.7% 的資料列是逐位元完全重複。留著會讓那些車在每個平均值裡被計算兩次

車號跨批次重複

88 個車號

每個路段是三段錄影接合而成，車號與影格編號都會重新編號，直接分組會產生不存在的換道

03

技術架構

從原始軌跡到一個站得住的數字

系統架構



每個階段都有獨立的輸出與日誌，任何一步都可以單獨重跑，不需要重跑整條流程。

技術堆疊

刻意維持輕量：全部是標準 Python 資料科學工具，沒有自製框架，任何人都能重跑。

層級	選用工具	承擔的工作
資料取得	requests + Socrata API	鍵集分頁下載，含重試與截斷偵測
儲存格式	Parquet + pyarrow	9.4M 筆壓縮至 126 MB，載入以秒計
資料處理	pandas + NumPy	向量化的軌跡分組、平滑與視窗運算
配對	SciPy cKDTree	標準化空間中的最近鄰配對
統計	statsmodels	OLS 搭配 HC3 異質變異穩健標準誤
視覺化	Matplotlib	色盲安全配色，全部直接標註
測試	合成軌跡	22 項已知答案的邏輯檢驗

全部相依套件列於 requirements.txt，共 7 項。

資料取得策略

第一版以 Socrata 的 offset 分頁下載。在 1,180 萬列的資料表上，頁數越深越慢，**18 分鐘沒有產出任何檔案**。

改為以 **vehicle_id** 區間分頁，資料庫可直接走索引：

實測 **81 萬列 49 秒**，且整個鍵範圍速度穩定。

程式另外檢查每次請求是否觸及列數上限。Socrata 觸及上限時是**安靜截斷**，不會報錯，那會讓整批車輛憑空消失而輸出看似正常。

錯誤做法

\$offset 深層分頁，效能隨頁數劣化

採用做法

WHERE vehicle_id >= lo AND < hi，走索引

處理流程



六個編號腳本依序執行，每一步寫出自己的日誌與中間產物，任何一步都可以單獨重跑。

事件偵測邏輯

基本判準是同一台車的車道編號與前一格不同。但原始判準會產生大量假事件，因此加上三道過濾：

穩定性 換道前後各須在同一車道維持 3 秒，擋掉判讀跳動與連續蛇行

必須有後車 沒有人承受代價就沒有東西可量

只留主線車道 匝道上的換道是被迫匯入，成因不同

原始換道 4,031

→ 穩定性過濾後 2,955

有後車 2,914


→ 資料完整 2,531

反事實設計

「換道後後車掉了 3.9 公里」本身**什麼都沒有證明**。壅塞車流本來就在不停地忽快忽慢。

因此每一筆事件都對照一組**沒有發生換道、但條件相同**的時刻：該車在整個視窗內都待在同一車道。

報告的外部成本是**兩組的差值**，不是事件組的原始掉幅。



兩條曲線在換道前完全重疊、之後才分開，這是配對有效的視覺證據，也是整份分析最有說服力的一張圖。

配對變數的選擇

三個變數全部嚴格在事件發生前量測。這個選擇踩過兩次坑，每一次都改變了答案。

配對變數	意義	為什麼必要
baseline_kmh	事前速度	速度水準直接決定可能的掉幅
pre_trend_kmh	事前是加速或減速	只配速度會選到剛從堵塞加速出來的車，該組平均加速 23%
headway_pre_ft	事前車距	前方空間決定反應餘裕
headway_at_t	換道當下車距	刻意排除 屬於事後變數，配它等於把要量的機制配掉

使用事後車距配對，會讓結論從 +0.76 變成 -0.35，**正負號完全相反**。

配對品質驗證

不以宣稱代替檢查。以下用的是估計式從未看過的欄位，因此是獨立驗證而非循環論證。

	事前車距	換道當下	變化
換道事件	106.3 ft	63.7 ft	-42.6 ft
配對對照組	105.8 ft	102.7 ft	-3.2 ft

事件組的後車在換道瞬間失去 42.6 英尺車距，對照組只失去 3.2 英尺。這同時證明偵測到的確實是切入，且對照組確實未被干擾。

統計方法

兩種方法互相檢查，而不是只用其中一種。

最近鄰配對

不假設函數形式

只要求拿條件相似的來比。在走走停停的車流中，速度與掉幅的關係明顯非線性

Bootstrap 區間

5,000 次重抽

每一個差異都報 95% 信賴區間而非點估計。固定亂數種子，結果完全可重現

OLS 迴歸

HC3 穩健標準誤

分離「貨車效應」與「貨車在哪裡換道」。壅塞以連續變數進入，避免二分法丟失變異

配對可檢查共變數平衡，迴歸可同時控制多個干擾因素，兩者結論一致。

04

分析結果

三個層次的發現，與一個推翻假設的結論

結果一 換道確實有代價

後車多掉的速度

+0.76 km/h


95% 信賴區間 +0.44 至 +1.09

恢復時間延遲


+0.27 秒

95% 信賴區間 +0.15 至 +0.40

兩個數字都是相對於配對對照組的差值。壅塞情境下的絕對代價明顯高於車流順暢時。



結果二 貨車的代價反而更低



貨車切入讓後車少掉 **1.62 km/h**，恢復也快 **0.98 秒**。

貨車換道頻率本來就較低：每車小時 7.7 次，小客車 10.7 次。

貨車事件僅 54 筆，對比小客車 2,418 筆。因此全部報信賴區間而非點估計。這個結果值得注意，是因為它推翻了專案原本的假設，不是因為它精確。

結果三 迴歸分析

原始的車種差異可能只反映貨車在什麼地方、什麼時候換道。控制之後才看得出機制。

變數	係數	p 值	判讀
是否為貨車	-1.364	0.468	不顯著
周圍車流平均速度	-0.351	9e-67	高度顯著
後車原本速度	+0.470	1e-151	顯著
車距	-0.035	3e-24	顯著
貨車 × 車流速度	+0.057	0.406	不顯著

若機制真是「貨車又大又重」，車種係數應該撐得過控制變數。它沒有。撐過去的是路況。

核心結論

外部成本取決於時機 不取決於車種

周圍車流每慢 1 km/h，同一個駕駛動作就多造成 0.35 km/h 的擾動。針對車種的管制瞄錯了變數，針對時機與間距的規範才是對的。

誠實的限制

以下數字對本專案的結論不利，但仍然列出，因為分析的可信度來自這裡。

凹陷深度

+0.76 km/h

顯著

恢復時間

+0.27 秒

顯著

後車淨損失時間

+0.03 秒

信賴區間跨過 0

擾動是**尖銳而短暫**的，不是持續的損失。本分析**不支持**「一次換道讓後車損失可測量的行車時間」這種說法。擾動是否會向上游放大成連鎖壅塞，這份資料的路段只有 50028 至 640 公尺，無法回答。

05

商業價值

從一個統計結論到一項可販售的服務

服務構想 壅塞外部成本評分

這個發現可以直接產品化為給車隊業者的 **Congestion Externality Score**。

輸入是業者為了法規遵循與保險**本來就已經在蒐集**的 GPS 軌跡，不需要加裝任何硬體。

輸出是每位駕駛、每條路線、每個時段造成了多少對周圍車流的擾動。

導入成本低，因為資料來源已經存在，缺的只是一個沒有人做的量測方法。

輸入

既有 telematics GPS 軌跡

輸出

駕駛 × 路線 × 時段的外部成本評分

三個讓它稱得上智慧的機制

自動化只是把人工流程變快。以下三點是這項服務與規則式評分的本質差異。

依情境定價

不是固定罰分

迴歸顯示周圍車流每慢 1 km/h，同一動作多造成 0.35 km/h 擾動。評分依實測路況加權每個事件

以實測行為為標竿

不是抽象理想值

資料顯示職業駕駛造成的代價本來就低於一般小客車駕駛。目標是一個已被觀測到的標準

閉環學習

會驗證自己

輔導改變行為，改變被重新量測，模型被重新估計。服務在學習什麼有效，而非宣稱

第三點是關鍵：沒有閉環的評分系統無法證明自己有用。

市場對標與差異

車隊行為評分已是成熟的產品類別，但現有產品全部衡量同一個面向。

產品	衡量對象	是否衡量外部成本
Samsara	駕駛自身風險：急煞、超速、分心	否
Geotab	駕駛自身風險與油耗	否
Lytx	以影像判定的駕駛自身風險行為	否
本專案構想	駕駛對周圍車流造成的擾動	是

差異不在演算法，而在**衡量對象**。這是一個既有市場裡尚未被佔據的位置。

AI 與資料分析的分工

資料分析負責識別。配對、分層與穩健迴歸回答「有多大，以及是不是真的」。這部分必須維持可解釋，因為會影響駕駛薪酬的評分必須能對駕駛解釋。

AI 延伸到三個分析到不了的地方：

規模化 — 本專案的偵測器需要每秒 10 筆的軌跡，真實車隊只有每秒 1 筆的消費級 GPS。以 NGSIM 為標註訓練資料可訓練序列模型。

逐事件反事實 — 直接預測那一台後車在沒有被切入時的速度。

行為發現 — 對軌跡分群，浮現沒有想過要假設的模式。

分析驗證 AI

以配對估計作為模型的驗證基準

為什麼必要

沒有這個檢查，模型是不可證偽的

落地路徑



係數必須在本地資料重新估計。NGSIM 在這個架構中的角色是**有標註的訓練與驗證資料**，不是結論來源。

06

工程品質

讓這份分析可以被檢驗

測試與可重現性

核心偵測邏輯有 **22 項合成軌跡檢驗**。測試資料是手工構造的，所以正確答案已知。

檢驗涵蓋：單格跳動、連續蛇行、注入固定減速幅度、不恢復的截斷標記、以及跨錄影批次的假換道。

完整流程重跑後，**每一個數字都相同**，連 bootstrap 信賴區間到小數點後兩位都一致。

一鍵重跑

bash scripts/run_all.sh · 約 15 分鐘

固定種子

20260919 · 保證 bootstrap 結果可重現

四個資料缺陷與發現過程

這四個缺陷都會產出看起來完全正常的結果。其中三個在摘要統計上不可見。

編號	缺陷	如何被發現
D5	兩段錄影時間連續，批次切不開，88 個車號撞號	不相干的當機
D8	第一版對照組在整個視窗內平均加速 23%	把曲線畫出來
D9	官方資料表含 704,000 筆完全重複的資料列	不相干的當機
D10	配對使用事後變數，結論正負號翻轉	重新檢視因果順序

專案檔案結構

編號腳本依序執行，每一步都寫出自己的日誌與中間產物。

路徑	內容
scripts/01-04	下載、事件偵測、統計分析、圖表產出
src/ngsim.py	共用常數、載入器與單位換算
tests/	22 項合成軌跡檢驗
docs/decision-log.md	11 條決策紀錄，含四個缺陷的來龍去脈
docs/methodology.md	完整方法論，逐一說明每個視窗與門檻
outputs/	圖表、結果表、results.json 與執行日誌

後續發展

這份分析回答了一階問題，也明確標示出自己答不了的部分。

擾動的傳播

資料限制

單一後車、10 秒視窗量到的是一階效果
。擾動是否向上游放大成連鎖壅塞，需要更長的觀測路段

本地係數重估

方法移植

2005 年美國高速公路的車輛組成與
2026 年的營運環境不同。方法可移植
，係數必須重新估計

低頻軌跡偵測

AI 延伸

以 NGSIM 為標註資料，訓練模型在每秒 1 筆的消費級 GPS 上辨識同樣的駕駛動作

變換車道的外部成本

完整程式碼、決策日誌與方法論皆為開源
